연세대학교 정보대학원 | 비즈니스 AI 빅데이터 분석 전공

2025년 12월 석사 학위논문

양자화된 대규모 언어 모델에서의 간접 프롬프트 인젝션 탐지 강건성 분석

Analysis of Robustness for Indirect Prompt Injection Detection in Quantized LLMs

BACKGROUND

연구 배경 및 목적

보안 위협: 프롬프트 인젝션

LLM 에이전트가 외부 문서를 처리할 때, 악의적인 명령어가 포함된 **간접 프롬프트 인젝션**에 노출되어 의도치 않은 동작을 수행할 위험이 있습니다.

지시문과 외부 데이터를 모델이 구분하지 못하는 문제

현실적 제약: 자원 효율성

서비스 배포 환경에서는 VRAM 용량과 추론 지연 시간(Latency)의 한계로 인해 **모델 양자화(Quantization)**가 요구됩니다.

메모리 절감 필수

본 과제: 탐지 강건성

양자화로 정밀도 손실이 발생하여 활성화 값(Activation) 분포가 변할 때, **보안 탐지 기법이 유효한가**에 대한 검증을 진행합니다.

INT8 환경에서의 탐지 성능 분석

EXISTING DEFENSE LIMITATIONS

기존 방어 솔루션의 한계

TSR 0.529

구조적 분리

SPOTLIGHTING

데이터 블록을 구분하는 태그나 구분자를 사용하여 지시와 데이터를 분리하는 방식입니다.

- 공격자가 삽입한 종료 태그 등의 공격에 취약함

TSR 0.60

임베딩 기반 분류기

EMBEDDING CLASSIFIER

입력 텍스트의 임베딩 벡터를 분석하여 악의적 패턴을 탐지하는 모델입니다.

- 일상 용어로 위장해 정상 출력을 유도하며 백그라운드 툴을 호출하는 공격 등에 취약

TSR 0.318

판별 모델

LLM JUDGE

별도의 고성능 LLM을 사용하여 입력값의 의도와 안전성을 검증하는 방식입니다.

- 과도한 비용과 높은 지연 시간(Latency)으로 인해 실무 적용이 제한적임

* TSR 수치는 Abdelnabi et al. (2025) [1]에서 인용

OUR APPROACH

연구 접근법의 차별성

내부 활성화 관찰의 필요성

조작의 어려움

모델 내부 히든 스테이트 신호는 외부 입력으로 직접 조작하기 어렵습니다.

양자화 환경 검증

실 서비스 배포를 위해서는 양자화가 사용되므로, 이러한 압축 환경에서도 탐지 기법이 유효한지 검증할 필요가 있습니다.

활성 델타 측정 방법론

1. **측정 지점 선정**

   문맥 정보가 압축되는 **마지막 토큰의 히든 스테이트**를 추출하여 모델의 실행 판단 근거를 분석합니다.

2. **대조 측정 (Contrastive)**

   사용자 지시 처리 시와 데이터 처리 시의 **신호 차이를 정량화**하여 의도 왜곡 여부를 판단합니다.

3. **심층 분석 및 판별**

   레이어별 활성 값을 추출하고 **선형 분류기**를 통해 최종적으로 공격 여부를 판별합니다.

METHODOLOGY

방법론: 활성화 Δ 기반 탐지 프로세스

INT8 양자화 환경 적용 (LLM.int8())

1 두 가지 입력 비교

Clean Input
Baseline
(only primary task)

VS

Potential Attack
With External
(include external context)

동일한 프롬프트에 대해 **외부 컨텐츠 유무**에 따른 두 가지 입력을 준비합니다.

2 활성화 델타(Δ) 계산

Δa

Difference Calculation

Extract Layers:
L15 L23 L31

특정 레이어에서 두 입력 간의 **활성화 값 차이 (Δa)**를 추출하여 의도 이탈을 수치화합니다.

3 IPI 탐지 분류

Logistic Regression

Clean **Attack**

추출된 델타 값을 **분류기 모델**에 입력하여 학습한 후 최종적으로 공격 여부를 판별합니다.

EXPERIMENT SETUP

실험 설계: 모델, 데이터, 지표

Target Models

FP32 vs INT8 비교

- **Phi-3** · Microsoft — 3.8B
- **Mistral** · Mistral AI — 7B
- **Llama-3** · Meta — 8B

Datasets

태스크 및 공격 시나리오

Clean (Normal)

SQuAD, HotPotQA

Attack (Injection)

AdvBench, TrustLLM, BeaverTails, Do-Not-Answer, Alpaca

Observation Layers

활성화 패턴 분석 지점

Input Layer — L15 — L23 — L31 — Output Layer

레이어 별 성능 차이 관찰을 위해 중반, 후반, 마지막 레이어 선정

Key Metrics

성능 및 효율성 지표

ROC-AUC

탐지 정확도 & 강건성

VRAM

메모리 사용량 (효율성)

KEY RESULTS

주요 결과: 성능 유지 + 자원 효율

탐지 성능 비교 (ROC-AUC)

FP32 vs INT8

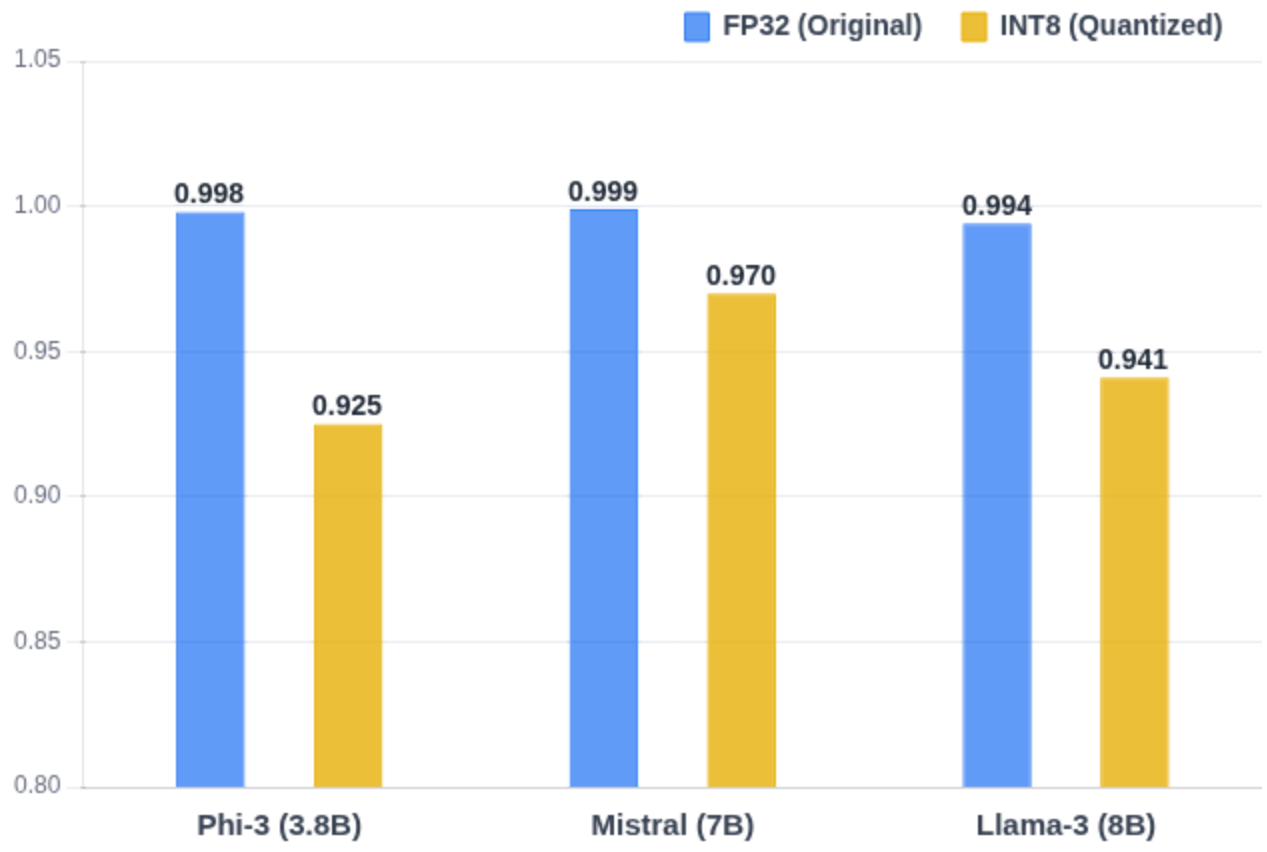

높은 탐지 강건성 유지

INT8 양자화 시에도 모든 모델이 **ROC-AUC 0.92 이상**을 기록했습니다.

자원 효율성 확보

가중치에서 메모리를 **절감**함으로써 효율성을 확보했습니다.

최적 탐지 레이어 이동

양자화 노이즈로 인해 최적 탐지 지점이 앞당겨지는 경향을 확인했습니다.

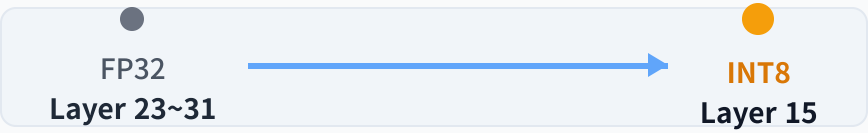

TECHNICAL DEEP DIVE

양자화 기반 Layer Shift 원인 분석

INT8 양자화 기본 원리

PRECISION DROP

Token Vector Input `4096 Floats`

하나의 토큰을 구성하는 4096차원 실수(Float) 벡터 (e.g. Mistral 7B)

↓

Max Value Scaling `Range: -127 ~ 127`

벡터 내 절대값 최대(Max(|x|))를 찾아 INT8 범위(127)로 매칭

↓

QUANTIZATION FORMULA

$$x_{int8} = round(x \times 127 / max(|x|))$$

Loss: -0.4

GENERAL QUANTIZATION CASE (EXAMPLE)

ORIGINAL (FLOAT)	→	QUANTIZED (INT8)
1.4	ROUNDING	**1.0**

* 단, Dettmers LLM.int8() 에서 Outlier 가중치는 FP16으로 보존되어 이 오차 계산에서 배제됨

레이어 심화에 따른 오차 누적

COMPOUNDING ERROR

Micro Error Input

일반적인 양자화 과정에서 발생한 미세 오차(예: 0.4)가 입력됩니다.

Matrix Multiplier

LLM의 수십 개 레이어를 통과하며 행렬 곱셈을 통해 오차가 증폭됩니다.

Layer Shift 발생

오차가 복리로 쌓여 최적 탐지 레이어 이동(Layer Shift)이 발생합니다.

연쇄 행렬 연산 과정에서 오차가 누적되나, Dettmers(LLM.int8())를 통해 주요 Outlier 가중치를 FP16으로 보존함으로써 오차 증폭 최소화

결론 및 시사점

INT8 양자화 환경에서의 탐지 강건성 확보

본 연구는 **INT8 양자화** 환경에서도 LLM의 간접 프롬프트 인젝션 탐지 성능이 **최대 ROC-AUC 0.9698**를 기록하며 성능이 유지됨을 확인했습니다.

실무 적용 시 고려사항

PRACTICAL USE CASES

- **보안 도메인 특성 반영**: 오탐(False Positive) 및 미탐(False Negative) 비용을 고려하여 단일 의존이 아닌 **다층 방어 체계 구축 권장**

기술적 기여

TECHNICAL CONTRIBUTIONS

- **현상 실증**: 양자화 오차의 누적과 전파가 초래하는 **Layer Shift 메커니즘** 실증
- **강건성 입증**: **Outlier 가중치 보존** 전략이 양자화된 모델의 보안 탐지 성능 유지에 기여함을 실증

REFERENCES

주요 참고문헌

1 **S. Abdelnabi, et al.**
"LLMail-Inject: A Dataset from a Realistic Adaptive Prompt Injection Challenge,"
arXiv preprint arXiv:2506.09956, 2025.

2 **S. Abdelnabi, et al.**
"Get my drift? Catching llm task drift with activation deltas,"
SaTML, 2025.

3 **T. Dettmers, et al.**
"LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale,"
NeurIPS, 2022.